

Elastic Weight Consolidation Done Right for Continual Learning

Xuan Liu, Xiaobin Chang*

CVPR 2026

Paper: <https://arxiv.org/abs/2603.18596>

Code: <https://github.com/scarlet0703/EWC-DR>

Bối cảnh

Trong Continual Learning (CL), model học tuần tự nhiều task — nhưng khi học task mới thường “quên” task cũ.

Hai hướng tiếp cận chính:

- Replay-based: lưu lại một phần dữ liệu cũ để ôn lại — gây lo ngại về bộ nhớ và quyền riêng tư
- Weight regularization: bảo vệ trọng số quan trọng bằng penalty — không cần lưu dữ liệu cũ, dễ triển khai

EWC (Elastic Weight Consolidation) là phương pháp weight regularization nền tảng, được dùng rộng rãi trong image classification, object detection, instruction tuning — do tính đơn giản và không cần exemplar.

Câu hỏi trọng tâm của bài báo

EWC liên tục cho hiệu suất kém hơn mong đợi — tại sao? Và có thể sửa được không?

EWC hoạt động như thế nào?

Sau khi train xong task $t - 1$, EWC tính ma trận tầm quan trọng Ω^{t-1} rồi thêm regularization loss khi học task mới:

$$\mathcal{L}_{reg} = \frac{\lambda}{2} \sum_i \Omega_i^{t-1} (\theta_i^{t-1} - \theta_i^t)^2$$

- λ : hệ số điều chỉnh độ mạnh của regularization
- Ω_i^{t-1} : importance (tầm quan trọng) của tham số i đối với task $t - 1$
- θ_i^{t-1} : giá trị tham số i sau khi train xong task $t - 1$
- θ_i^t : giá trị tham số i trong quá trình học task t

Ω được ước lượng qua Fisher Information Matrix (FIM):

$$\Omega_i^{\text{EWC}} = F_i = \mathbb{E} \left[\left(\frac{\partial \mathcal{L}_{CE}}{\partial \theta_i} \right)^2 \right]$$

Vấn đề 1: Gradient Vanishing trong EWC

Gradient của $\mathcal{L}_{CE}$ với logit z_k của FC layer, thống nhất cho mọi k :

$$\frac{\partial \mathcal{L}_{CE}}{\partial z_k} = p_k - y_k \quad \begin{cases} p_k = \text{Softmax}(\mathbf{z})_k : \text{xác suất dự đoán class } k \\ y_k \in \{0, 1\} : \text{nhãn one-hot} \end{cases}$$

Với class đúng $k = c$ (tức $y_c = 1$):

$$\frac{\partial \mathcal{L}_{CE}}{\partial z_c} = p_c - 1$$

Khi model dự đoán đúng với độ tự tin cao ($p_c \rightarrow 1$):

$$(p_c - 1)^2 \rightarrow 0 \Rightarrow \Omega_{w_c}^{EWC} = \mathbb{E} \left[(p_c - 1)^2 \cdot \left(\frac{\partial z_c}{\partial w_c} \right)^2 \right] \approx 0$$

Với class sai $k \neq c$: $p_k \rightarrow 0 \Rightarrow p_k^2 \rightarrow 0 \Rightarrow \Omega_{w_k}^{EWC} \approx 0$ tương tự.

Gradient Vanishing

FIM đánh giá thấp importance của toàn bộ FC layer khi model đang dự đoán đúng với độ tự tin rất cao -> những tham số quan trọng không được bảo vệ.

Minh họa: Gradient Vanishing (Figure 2)




Figure 2. A Case Study of Gradient Vanishing.

Vấn đề 2: Redundant Protection trong MAS

MAS đo importance bằng độ nhạy của output theo tham số, dùng ℓ_2 norm:

$$\Omega_i^{\text{MAS}} = \left\| \frac{\partial \mathcal{L}_2}{\partial \theta_i} \right\|_1, \quad \mathcal{L}_2 = \|f(x; \theta)\|_2$$

- $f(x; \theta)$: đầu ra của mạng (vector logits) với đầu vào x và tham số θ
- $\|\cdot\|_2$: ℓ_2 norm; $\|\cdot\|_1$: ℓ_1 norm

Với FC layer, gradient của $\mathcal{L}_2$ theo logit z_k của class k :


$$\frac{\partial \mathcal{L}_2}{\partial z_k} = \frac{z_k}{\|\mathbf{z}\|_2} \Rightarrow \Omega_{w_k}^{\text{MAS}} = \frac{|z_k|}{\|\mathbf{z}\|_2} \cdot \left| \frac{\partial z_k}{\partial w_k} \right|$$

MAS không dùng softmax $\Rightarrow$ logit âm lớn ($z_k \ll 0$) cho $|z_k|$ lớn $\Rightarrow$ importance cao. Nhưng $p_k \approx 0$ với k sai $\Rightarrow$ bảo vệ tham số vô nghĩa.


Redundant Protection

MAS bảo vệ quá mức các tham số ứng với class sai có logit âm lớn — làm giảm plasticity khi học task mới.

Minh họa: Redundant Protection (Figure 3)



(a) The logit z_k of k -th class. Ground truth at 0.



(b) Importance of the FC layer weights, summed per class.

Figure 3. A Case Study of Redundant Protection.

Giải pháp: Logits Reversal (LR)

Ý tưởng: đảo ngược logits trước khi tính FIM.

$$\tilde{z}_k = -z_k \quad \Rightarrow \quad \tilde{p}_k = \frac{e^{-z_k}}{\sum_j e^{-z_j}}$$

($\tilde{z}_k$: logit đã đảo; $\tilde{p}_k$: xác suất softmax trên logit đảo)

Gradient của $\tilde{\mathcal{L}}_{CE} = -\sum_k y_k \log \tilde{p}_k$ theo z_k , thống nhất cho mọi k :

$$\frac{\partial \tilde{\mathcal{L}}_{CE}}{\partial z_k} = y_k - \tilde{p}_k$$

Importance dưới LR (w_k : trọng số FC layer ứng với class k):

$$\Omega_{w_k}^{LR} = \mathbb{E} \left[(y_k - \tilde{p}_k)^2 \cdot \left(\frac{\partial \tilde{z}_k}{\partial w_k} \right)^2 \right]$$

Phân tích: khi z_c lớn $\Rightarrow \tilde{p}_c = \text{softmax}(-z_c)$ nhỏ $\Rightarrow (1 - \tilde{p}_c)^2$ lớn $\Rightarrow \Omega_{w_c}^{LR}$ cao. Khi $z_k \ll 0$ (class sai) $\Rightarrow \tilde{p}_k \approx 1$ nhưng gradient $\partial \tilde{z}_k / \partial w_k$ nhỏ $\Rightarrow$ đóng góp thấp.

Thực nghiệm

Hai bộ tác vụ CL:

EFCIL (Exemplar-Free Class-Incremental Learning):

- CIFAR-100 (100 class, 32×32)
- ImageNet-Subset (100 class, 224×224)
- Tiny-ImageNet (200 class, 64×64)
- Big-start: 50 class ban đầu, $T=5/10/20$ task tăng dần
- Equally-split: chia đều $T=5/10/20$
- Backbone: ResNet-18, framework: PyCIL

MCIT (Multimodal Continual Instruction Tuning):

- CLiMB benchmark: VQAv2 $\rightarrow$ NLVR2 $\rightarrow$ SNLI-VE $\rightarrow$ VCR

Các phương pháp so sánh:

- EWC (Kirkpatrick et al., 2017)
- Online EWC (Schwarz et al., 2018)
- SI — Synaptic Intelligence (Zenke et al., 2017)
- MAS — Memory Aware Synapses (Aljundi et al., 2018)

Metrics:

- $A_{last} = A_T$: accuracy sau task cuối T
- $A_{avg} = \frac{1}{T} \sum_{t=1}^T A_t$: trung bình accuracy qua T task; A_t là accuracy đo trên toàn bộ class đã thấy sau task t
- $\mathcal{F}_{t,j} = \frac{a_{j,j} - a_{t,j}}{a_{j,j} - a_{j-1,j}}$ (MCIT): forgetting transfer; $a_{t,j}$ là accuracy trên task j sau khi train đến task t

Kết quả EFCIL — CIFAR-100 (Table 1)

Table 1. EFCIL performance on CIFAR-100. Reported results represent means across three independent trials.

method	Big start						Equally split					
	T=5		T=10		T=20		T=5		T=10		T=20	
	A_{last}	A_{avg}	A_{last}	A_{avg}	A_{last}	A_{avg}	A_{last}	A_{avg}	A_{last}	A_{avg}	A_{last}	A_{avg}
EWC	14.61	32.82	11.53	27.02	6.20	19.61	17.80	39.02	10.62	27.90	5.48	18.13
online EWC	29.70	45.65	26.36	40.36	17.63	31.71	26.13	43.97	17.45	33.04	11.52	25.49
SI	19.26	37.68	11.33	27.45	5.62	17.62	13.10	29.84	9.91	23.58	7.98	20.72
MAS	35.37	48.32	29.09	43.24	19.98	34.77	29.45	43.68	23.41	37.84	13.24	27.39
EWC-DR	50.23	63.75	44.88	60.94	35.86	53.45	46.89	61.47	29.41	46.01	18.00	33.52

Kết quả EFCIL — ImageNet-Subset (Table 2)

Table 2. EFCIL performance on ImageNet-Subset. Reported results represent means across three independent trials.

method	Big start						Equally split					
	T=5		T=10		T=20		T=5		T=10		T=20	
	A_{last}	A_{avg}	A_{last}	A_{avg}	A_{last}	A_{avg}	A_{last}	A_{avg}	A_{last}	A_{avg}	A_{last}	A_{avg}
EWC	11.44	26.57	5.76	15.52	3.73	9.86	20.78	42.37	10.60	28.75	5.28	18.74
online EWC	23.56	46.68	16.12	39.71	13.00	32.74	26.64	46.58	12.78	29.72	6.34	18.91
SI	9.19	24.56	4.80	13.66	2.93	8.30	17.83	40.19	9.10	26.44	4.77	16.77
MAS	21.06	42.59	13.72	31.17	7.86	22.44	45.33	62.99	24.36	44.16	11.47	26.83
EWC-DR	66.18	76.00	58.94	70.99	43.43	59.59	54.80	68.46	35.02	54.55	17.17	34.68

Kết quả EFCIL — Tiny-ImageNet (Table 3)

Table 3. EFCIL performance on Tiny-ImageNet. Reported results represent means across three independent trials.

method	Big start						Equally split					
	T=5		T=10		T=20		T=5		T=10		T=20	
	A_{last}	A_{avg}	A_{last}	A_{avg}	A_{last}	A_{avg}	A_{last}	A_{avg}	A_{last}	A_{avg}	A_{last}	A_{avg}
EWC	9.74	19.92	7.00	15.35	4.56	12.51	20.15	32.10	11.42	23.52	5.34	15.58
online EWC	27.02	39.63	20.03	31.76	18.52	31.96	24.01	35.41	16.77	27.63	10.95	19.44
SI	7.46	17.59	4.04	10.10	2.24	5.68	12.14	27.02	6.97	19.00	3.81	12.41
MAS	25.53	38.45	15.32	27.97	11.67	25.98	20.04	32.95	11.56	24.63	7.41	17.51
EWC-DR	38.24	47.00	31.43	42.88	23.64	37.56	28.67	39.52	21.46	32.79	12.09	22.62

Đóng góp chính:

- Phân tích gradient-based đầu tiên chỉ ra nguyên nhân gốc rễ khiến EWC yếu: gradient vanishing
- Phát hiện redundant protection trong MAS: logit âm lớn bị bảo vệ quá mức do thiếu softmax normalize
- Đề xuất Logits Reversal (LR) — $\tilde{z}_k = -z_k$
- EWC-DR vượt trội EWC và các biến thể trên mọi dataset và giao thức được đánh giá

Ý nghĩa rộng hơn:

- Framework phân tích gradient-based cho weight regularization CL
- Mở ra hướng thiết kế các phương pháp regularization tốt hơn dựa trên phân tích gradient
- EWC-DR là baseline mạnh cho nghiên cứu CL tương lai — đặc biệt trong EFCIL và MCIT